

UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ciencias

Escuela de Ciencias de la Computación

---

# Sistema Distribuido para Entrenamiento de IAs

con Algoritmo de Consenso RAFT

---



CC4P1 – Programación Concurrente y Distribuida  
Final 2025-I

## Integrantes

Apellidos y Nombres	Código
1. Espinoza Valera, Cinver Alem	20220277F
2. Mercado Taype, Ariana Aracely	20221540B
3. Cadillo Tarazona, Jharvy Jonas	20210184E
4. Centeno Leon, Martin Alonso	20210161E
5. Calapuja Apaza, Luis Alberto	20150377G

Lima, Perú  
2025

---

# Índice

---

<b>1. Introducción</b>	<b>2</b>
<b>2. Arquitectura del Sistema</b>	<b>2</b>
2.1. Visión General . . . . .	2
2.2. Estructura de Directorios . . . . .	3
<b>3. Componentes del Sistema</b>	<b>4</b>
3.1. Cliente Python . . . . .	4
3.2. Servidor Node.js . . . . .	4
3.3. Core Java . . . . .	4
<b>4. Algoritmo de Consenso RAFT</b>	<b>5</b>
4.1. Estados del Nodo . . . . .	5
4.2. Mensajes RPC . . . . .	5
4.3. Proceso de Elección . . . . .	5
<b>5. Protocolo de Comunicación</b>	<b>6</b>
5.1. Formato de Mensajes . . . . .	6
5.2. Configuración de Puertos . . . . .	6
<b>6. Flujo de Operaciones</b>	<b>6</b>
6.1. Fase 1: Entrenamiento . . . . .	6
6.2. Fase 2: Predicción (Testeo) . . . . .	7
<b>7. Concurrencia y Paralelismo</b>	<b>7</b>
7.1. Multi-Threading en Java . . . . .	7
7.2. Concurrencia en Node.js . . . . .	7
<b>8. Ejecución y Pruebas</b>	<b>7</b>
8.1. Comandos de Ejecución . . . . .	7
8.2. Pruebas de Estrés . . . . .	7
<b>9. Conclusiones</b>	<b>8</b>


# 1. Introducción


El presente informe documenta el desarrollo de un **Sistema Distribuido para el Entrenamiento y Consumo de Modelos de Inteligencia Artificial**, implementado como proyecto final del curso de Programación Concurrente y Distribuida.

## Objetivo del Sistema

Diseñar e implementar un sistema distribuido que permita el entrenamiento y consumo de modelos de IA de manera **paralela, distribuida y concurrente**, garantizando la gestión adecuada de los modelos mediante el algoritmo de consenso **RAFT**.

El sistema se desarrolló utilizando una arquitectura híbrida con tres lenguajes de programación:

 **Python:** Cliente Desktop con interfaz gráfica y scripts de pruebas

 **Node.js:** Servidores (Workers) con algoritmo RAFT y monitoreo HTTP

 **Java:** Motor de IA con redes neuronales y multi-threading

# 2. Arquitectura del Sistema

## 2.1 Visión General

El sistema implementa una arquitectura de tres capas que separa responsabilidades y cumple con el requisito de múltiples lenguajes de programación.

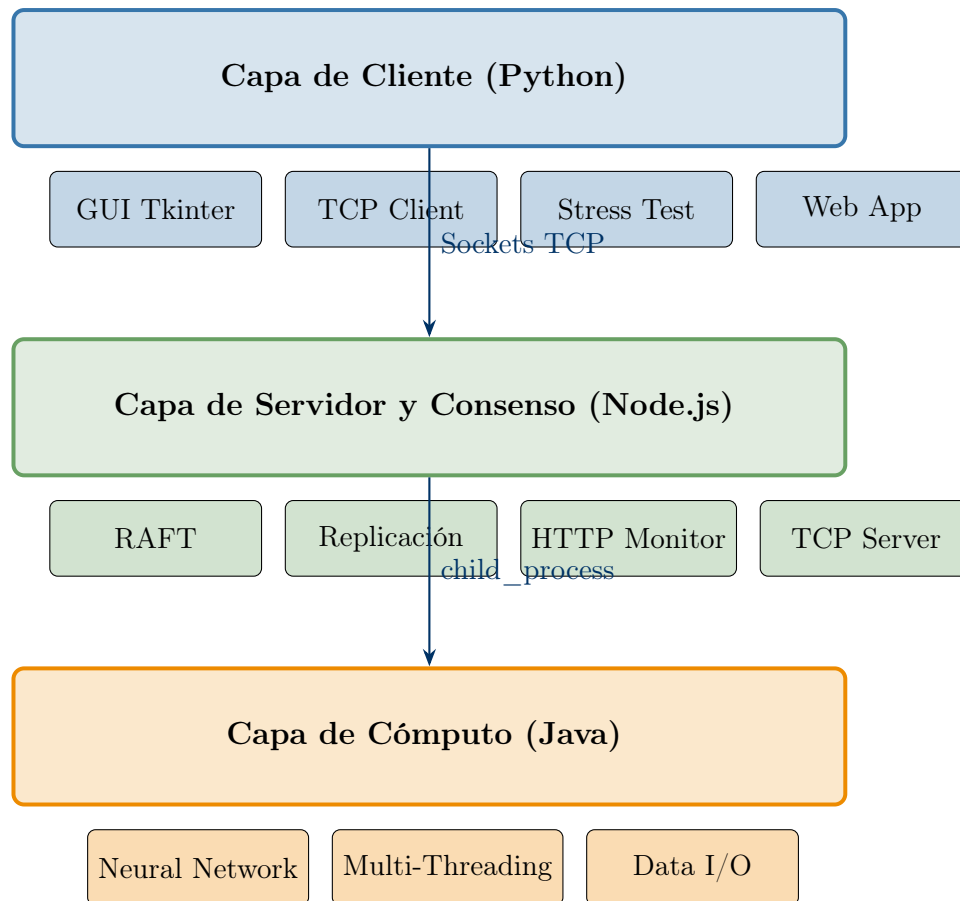


Figura 1: Arquitectura de tres capas del sistema

## 2.2 Estructura de Directorios

### Organización del Proyecto

```

proyecto/
src/
  client/      # Python: GUI, TCP Client, Web App
  server/      # Node.js: RAFT, TCP, HTTP
    node_worker/
      raft/    # Algoritmo de consenso
      tcp/     # Servidores TCP
      http/    # Monitor web
      java/    # Integración con Core
  core/        # Java: Red Neuronal
    src/
      nn/      # Clases de red neuronal
      math/    # Operaciones matriciales
      data/    # Carga de datos
      concurrent/ # Multi-threading
  Makefile
  README.md
  
```

### 3. Componentes del Sistema

#### 3.1 Cliente Python

El cliente proporciona dos interfaces para interactuar con el sistema:

pythonblue!20 Componente	Archivo	Función
GUI Desktop	gui_app.py	Interfaz Tkinter para entrenamiento y predicción
Cliente Web	web_app.py	Interfaz Flask accesible por navegador
TCP Client	tcp_client.py	Comunicación con el clúster RAFT
Stress Test	stress_test.py	Pruebas de carga con 1000+ peticiones

Cuadro 1: Componentes del cliente Python

El cliente implementa **reconexión automática** cuando el líder RAFT cambia, rotando entre los nodos disponibles.

#### 3.2 Servidor Node.js

Cada nodo del clúster ejecuta los siguientes módulos:




Figura 2: Módulos de un Worker Node.js

#### 3.3 Core Java

El motor de IA implementa una red neuronal multicapa desde cero, sin frameworks externos:

- **Matrix.java:** Operaciones matriciales (multiplicación, transpuesta, Hadamard)
- **ActivationFunction.java:** Sigmoid, ReLU, Tanh, Softmax
- **NeuralNetwork.java:** Forward/Backpropagation, serialización
- **MultiThreadTrainer.java:** Entrenamiento paralelo usando `ExecutorService`
- **DataLoader.java:** Lectura de CSV y normalización de datos

**Interfaz CLI del Core**

```
java -jar core.jar train <input_path> <model_id>
java -jar core.jar predict <model_id> <input_data>
java -jar core.jar info
```

## 4. Algoritmo de Consenso RAFT

### 4.1 Estados del Nodo

El algoritmo RAFT implementado maneja tres estados:

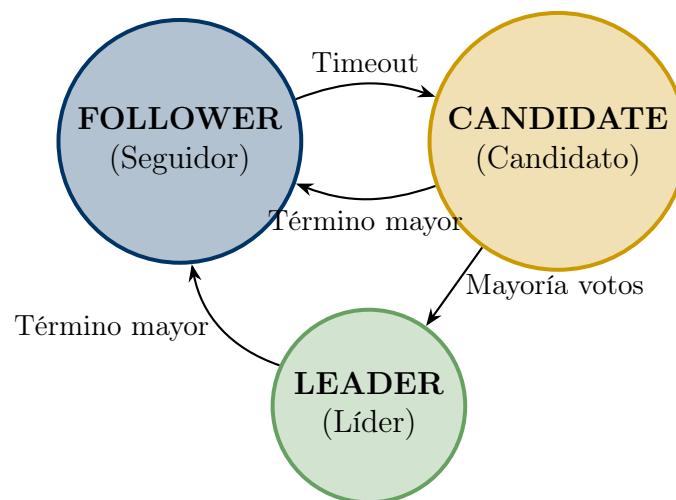


Figura 3: Máquina de estados RAFT

### 4.2 Mensajes RPC

raftpurple!20 Tipo	Descripción
REQUEST_VOTE	Solicitud de voto durante elección
REQUEST_VOTE_RESPONSE	Respuesta con voto otorgado o denegado
APPEND_ENTRIES	Heartbeats y replicación de logs
APPEND_ENTRIES_RESPONSE	Confirmación de replicación

Cuadro 2: Tipos de mensajes RAFT

### 4.3 Proceso de Elección

1. El nodo incrementa su término actual
2. Vota por sí mismo y envía REQUEST\_VOTE a todos los peers
3. Espera respuestas hasta obtener mayoría (quórum)
4. Si obtiene mayoría, se convierte en líder
5. Si recibe heartbeat de líder válido, vuelve a follower

## 5. Protocolo de Comunicación

### 5.1 Formato de Mensajes

Todos los mensajes usan **JSON sobre TCP** con delimitador `\n`:

Listing 1: Petición de Entrenamiento

```

1 {
2   "type": "TRAIN_REQUEST",
3   "payload": {
4     "data_content": "base64_encoded_csv",
5     "model_name": "modelo_v1"
6   }
7 }
```

Listing 2: Petición de Predicción

```

1 {
2   "type": "PREDICT_REQUEST",
3   "payload": {
4     "model_id": "modelo_v1",
5     "input_vector": [0.5, 0.1, 0.9]
6   }
7 }
```

### 5.2 Configuración de Puertos

uniblue!20 Nodo	Puerto Cliente	Puerto Peer	Puerto HTTP
Node_A	5000	6000	8080
Node_B	5001	6001	8081
Node_C	5002	6002	8082

Cuadro 3: Configuración de puertos por nodo

## 6. Flujo de Operaciones

### 6.1 Fase 1: Entrenamiento

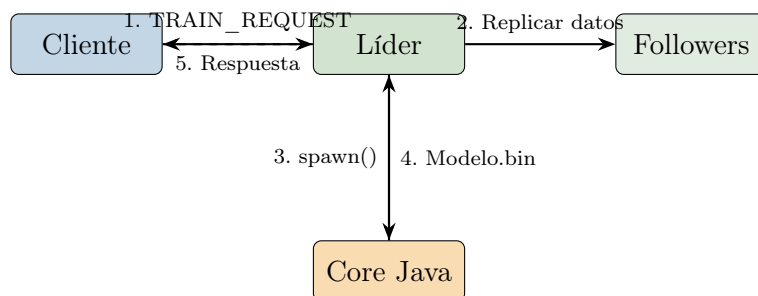


Figura 4: Flujo de entrenamiento distribuido

## 6.2 Fase 2: Predicción (Testeo)

El cliente envía una solicitud de predicción al líder, quien ejecuta el modelo entrenado en Java y retorna el resultado. El consenso RAFT garantiza que todos los nodos tienen acceso al modelo replicado.

## 7. Concurrency y Paralelismo

### 7.1 Multi-Threading en Java

El componente `MultiThreadTrainer` divide el trabajo entre todos los núcleos disponibles:

Listing 3: Inicialización de threads

```
1 int numThreads = Runtime.getRuntime().availableProcessors();
2 ExecutorService executor = Executors.newFixedThreadPool(numThreads);
   ;
```

**Técnica utilizada:** *Paralelismo de datos* – cada thread procesa un batch diferente del dataset simultáneamente.

### 7.2 Concurrency en Node.js

Node.js maneja múltiples conexiones TCP de forma asíncrona mediante su *event loop*, permitiendo:

- Conexiones simultáneas de múltiples clientes
- Comunicación con peers sin bloqueo
- Ejecución de Java como subprocesso (`child_process.spawn`)

## 8. Ejecución y Pruebas

### 8.1 Comandos de Ejecución

#### Makefile

```
make core          # Compila el núcleo Java
make server-nodes  # Inicia el clúster de 3 nodos
make client        # Inicia la interfaz gráfica
make client-web    # Inicia el cliente web (puerto 5005)
make clean         # Limpia binarios
```

### 8.2 Pruebas de Estrés

El script `stress_test.py` envía 1000 peticiones aleatorias para validar:

- Consistencia del algoritmo RAFT bajo carga



- Manejo correcto de cambios de líder
- Rendimiento del sistema (requests/segundo)

## 9. Conclusiones

1. Se implementó exitosamente un sistema distribuido con **tres lenguajes de programación** (Python, Node.js, Java) comunicándose mediante sockets TCP.
2. El algoritmo **RAFT** garantiza la consistencia de datos entre nodos, manejando correctamente elecciones de líder y replicación de logs.
3. El motor de IA en Java aprovecha **todos los núcleos del procesador** mediante `ExecutorService` para entrenamiento paralelo.
4. La arquitectura modular permite escalar horizontalmente agregando más nodos al clúster.
5. El sistema cumple con las restricciones del proyecto: uso exclusivo de sockets nativos, sin frameworks de IA ni librerías de comunicación externas.

### Repositorio del Proyecto

El código fuente completo está disponible en GitHub con documentación detallada de instalación y uso.